Viabilidad y sostenibilidad

Este documento describe los recursos que el prototipo requiere para operar en el piloto universitario del Entregable 2.

1. Costo marginal: 0 USD dentro del piloto

Recurso	Plan	Límite	¿Suficiente?
Modelo de lenguaje	Gemini, nivel gratuito	15 req/min · 1 M tokens/día	Sí. Un turno ≈ 3 llamadas ≈ 2 500 tokens
Alojamiento	Equipo del usuario + túnel de Cloudflare	gratuita	Sí. La aplicación es liviana
Modelo de asistencia	scikit-learn, local	sin costo	Sí
Clasificador de necesidad	scikit-learn, local (D5)	sin costo	Sí
Datos	Data Pack sintético	sin costo	—

No se requiere tarjeta de crédito en ninguna etapa. Véase `PUBLICACION.md`.

Estimación para el piloto universitario. Si atienden 826 estudiantes (el segmento prioritario de UNI_NOVA_AETHER) y cada uno registra 4 días en Pulse y abre 2 conversaciones:

Concepto	Cálculo	Total
Turnos de conversación	1 652 chats × 3 llamadas × 2 500 tokens	~12,4 M tokens
Frases de Pulse	3 304 registros × ~200 tokens	~0,7 M tokens
Total		**~13 M tokens/mes**

Con el límite gratuito de 1 M/día (≈30 M/mes), **el piloto completo se sitúa dentro del plan gratuito**. Si el alcance se duplicara, bastaría el nivel de pago más bajo del proveedor; el costo seguiría siendo marginal frente al de un profesional de bienestar.

2. Costo por etapa de despliegue

Etapa	Volumen	Costo estimado	Observación
Demostración de semifinal	~50 usuarios	0 USD	—
Piloto universitario	826 estudiantes	0 USD	Dentro del nivel gratuito
Institución completa	~6 700 estudiantes	15–40 USD/mes	Requiere el nivel de pago siguiente
Red regional	>100 000	Modelo abierto en servidor propio	El diseño ya lo permite

3. Viabilidad técnica

Arranque. La aplicación carga el Data Pack y entrena dos modelos en aproximadamente 25 segundos. No requiere base de datos: el estado reside en memoria durante la sesión.

Reproducibilidad. La agenda se genera con una semilla fija (`random.Random`), por lo que la demostración produce exactamente los mismos números en cada ejecución. Esta propiedad es deliberada: garantiza que el equipo de evaluación observe lo mismo que observó el equipo autor, y resulta indispensable para la grabación del video.

Degradación controlada. Cada invocación al modelo dispone de respaldo. En ausencia de clave, la aplicación opera íntegramente con el clasificador de D5 y plantillas de respaldo. **La aplicación no puede colapsar ante un fallo de red**, condición esencial para una demostración en vivo.

Portabilidad. Cambiar de institución es una variable de entorno:

```
set AETHERA_INSTITUCION=INST_NEXUS
```

El Data Pack incluye tres instituciones y cinco distritos, y las líneas de ayuda son bilingües (Perú, Chile). No existe código específico de UNI_NOVA_AETHER fuera de esa constante.

4. Ruta de crecimiento

1. **Agenda real.** Actualmente la agenda es simulada. Se sustituye `generar_agenda()` por una consulta al sistema de citas institucional; el resto del motor no se modifica.
1. **Identidad.** El `student_id` procede hoy del selector de demostración. Se sustituye por el inicio de sesión institucional, conservando que el sistema nunca recibe `anxiety_band` .
1. **Persistencia.** El registro de Pulse pasa de memoria a almacenamiento cifrado con control de acceso por roles y bitácora, conforme a lo declarado en la ficha de IA responsable.

1. **Modelo de lenguaje.** Ya es intercambiable entre cuatro proveedores y el modo sin modelo.

5. Riesgos de viabilidad

Riesgo	Mitigación
Agotamiento de la cuota gratuita durante un evento	Respaldo sin modelo: la aplicación sigue operativa
La agenda real difiere de la simulada	El motor consume un `DataFrame` de esquema fijo, documentado en `servicios.generar_agenda`
Mantenimiento de un único archivo extenso	Arquitectura reorganizada en 16 módulos con verificaciones automatizadas
El modelo no generaliza fuera de UNI_NOVA_AETHER	Declarado; el clasificador se reentrena con las conversaciones de D5 de las demás instituciones
El Data Pack no puede distribuirse con el código	Plantilla `data/LEEME.txt` y un mensaje de arranque que identifica el archivo ausente