Viabilidad y sostenibilidad

Este documento describe los recursos que el prototipo requiere para operar en el piloto universitario del Entregable 2.

1. Costo marginal: 0 USD dentro del piloto

Recurso	Plan	Límite	¿Suficiente?
Modelo de lenguaje	Gemini, nivel gratuito	15 req/min · 1 M tokens/día	Sí. Un turno ≈ 3 llamadas ≈ 2 500 tokens
Alojamiento	Equipo del usuario + túnel de Cloudflare	gratuita	Sí. La aplicación es liviana
Modelo de asistencia	scikit-learn, local	sin costo	Sí
Clasificador de necesidad	scikit-learn, local (D5)	sin costo	Sí
Datos	Data Pack sintético	sin costo	—

No se requiere tarjeta de crédito en ninguna etapa. Véase `PUBLICACION.md`.

Estimación para el piloto universitario. Si atienden 826 estudiantes (el segmento prioritario de UNI_NOVA_AETHER) y cada uno registra 4 días en Pulse y abre 2 conversaciones:

Concepto	Cálculo	Total
Turnos de conversación	1 652 chats × 3 llamadas × 2 500 tokens	~12,4 M tokens
Frases de Pulse	3 304 registros × ~200 tokens	~0,7 M tokens
Total		**~13 M tokens/mes**

Con el límite gratuito de 1 M/día (≈30 M/mes), **el piloto completo se sitúa dentro del plan gratuito**. Si el alcance se duplicara, bastaría el nivel de pago más bajo del proveedor; el costo seguiría siendo marginal frente al de un profesional de bienestar.

2. Costo por etapa de despliegue y Plan de Adopción

Etapa	Volumen	Costo estimado	Observación
Demostración de semifinal	~50 usuarios	0 USD	Totalmente funcional
Piloto universitario	826 estudiantes	0 USD	Dentro de la capa gratuita, sin tarjeta
Institución completa	~6 700 estudiantes	15–40 USD/mes	Costo marginal despreciable
Red regional	>100 000	0 USD en cómputo propio	Modelos abiertos (Llama/Gemma) on-premise

Plan de adopción institucional en 3 fases

1. **Fase 1 · Conexión Plug & Play (Día 1 · Costo 0 USD):** La universidad no reconstruye su infraestructura. Se integra directamente en el aula virtual o LMS (Canvas, Blackboard o Moodle) mediante iframe o estándar LTI. Solo consume dos fuentes estandarizadas: el catálogo de servicios (D6) y el calendario académico (D7).
2. **Fase 2 · Piloto Focalizado sin Riesgo (Semanas 1 a 4 · Costo 0 USD):** Se habilita en una facultad piloto o durante semanas críticas de exámenes. El equipo de bienestar evalúa el uso real mediante el dashboard con k-anonimato (celdas < 10 suprimidas). No se requiere tarjeta de crédito ni presupuesto previo.
3. **Fase 3 · Escalamiento Sostenible (Mes 2 en adelante):** Expansión a todo el campus. A nivel institucional completo (~6 700 alumnos), el costo computacional de tokens es de apenas 15 a 40 USD mensuales.

Retorno de inversión (ROI) y sostenibilidad operativa

El sistema es financieramente viable porque no intenta sustituir la atención humana contratando nóminas clínicas masivas. Al clasificar la necesidad y canalizar el malestar cotidiano hacia el **Acompañamiento entre Pares** (`peer_support`), la capacidad de atención se amplía con estudiantes de ciclos superiores becados y formados. La retención de un solo estudiante en riesgo de deserción cubre con creces el costo computacional de toda la universidad.

3. Viabilidad técnica

Arranque. La aplicación carga el Data Pack y entrena dos modelos en aproximadamente 25 segundos. No requiere base de datos: el estado reside en memoria durante la sesión.

Reproducibilidad. La agenda se genera con una semilla fija (`random.Random`), por lo que la demostración produce exactamente los mismos números en cada ejecución. Esta propiedad es deliberada: garantiza que el equipo de evaluación observe lo mismo que observó el equipo autor, y resulta indispensable para la grabación del video.

Degradación controlada. Cada invocación al modelo dispone de respaldo. En ausencia de clave, la aplicación opera íntegramente con el clasificador de D5 y plantillas de respaldo. **La aplicación no puede colapsar ante un fallo de red**, condición esencial para una demostración en vivo.

Portabilidad. Cambiar de institución es una variable de entorno:

```
set AETHERA_INSTITUCION=INST_NEXUS
```

El Data Pack incluye tres instituciones y cinco distritos, y las líneas de ayuda son bilingües (Perú, Chile). No existe código específico de UNI_NOVA_AETHER fuera de esa constante.

4. Ruta de crecimiento

1. **Agenda real.** Actualmente la agenda es simulada. Se sustituye `generar_agenda()` por una consulta al sistema de citas institucional; el resto del motor no se modifica.
1. **Identidad.** El `student_id` procede hoy del selector de demostración. Se sustituye por el inicio de sesión institucional, conservando que el sistema nunca recibe `anxiety_band`.
1. **Persistencia.** El registro de Pulse pasa de memoria a almacenamiento cifrado con control de acceso por roles y bitácora, conforme a lo declarado en la ficha de IA responsable.
1. **Modelo de lenguaje.** Ya es intercambiable entre cuatro proveedores y el modo sin modelo.

5. Riesgos de viabilidad

Riesgo	Mitigación
Agotamiento de la cuota gratuita durante un evento	Respaldo sin modelo: la aplicación sigue operativa
La agenda real difiere de la simulada	El motor consume un `DataFrame` de esquema fijo, documentado en `servicios.generar_agenda`
Mantenimiento de un único archivo extenso	Arquitectura reorganizada en 16 módulos con verificaciones automatizadas
El modelo no generaliza fuera de UNI_NOVA_AETHER	Declarado; el clasificador se reentrena con las conversaciones de D5 de las demás instituciones
El Data Pack no puede distribuirse con el código	Plantilla `data/LEEME.txt` y un mensaje de arranque que identifica el archivo ausente