Entregable 2 · Desafío Ciudad Aethera · Misión M5 · Datos 100 % sintéticos del Data Pack.
Aethera es una ciudad universitaria ficticia del desafío binacional Chile–Perú.

1 · MODELOS Y HERRAMIENTAS

Herramienta	Modelo / técnica	Propósito
Clasificador, planificador, redactor	Gemini `gemini-3.5-flash-lite` (free tier)	Elegir 1 de 5 motivos **no clínicos**, 1 de 7 acciones y redactar. Nunca diagnostica
Asistencia	Regresión logística sobre **D2** (9 400)	Ordenar citas por P(asistir). AUC 0,567
Clasificador sin LLM	TF-IDF + regresión logística sobre **D5** (2 500)	Sustituye al LLM sin clave. **80,8 %** CV vs 20,5 % base

Principio rector: el modelo de lenguaje nunca decide datos, solo *qué hacer* y *cómo decirlo*. Servicios, fechas, horas y teléfonos salen de herramientas que leen el Data Pack; si el redactor los inventa, el guardrail de salida lo detecta y su respuesta se descarta por una plantilla verificada. Proveedores intercambiables; **sin clave de API la app funciona completa**.

2 · DATOS UTILIZADOS

Solo los siete datasets sintéticos del Data Pack: **D1** (12 000) · **D2** (9 400) · **D3** (130 000) · **D4** (6 000) · **D5** (2 500) · **D6** (15) · **D7** (32). **No se usan datos reales ni externos sensibles**; no hay identificadores de personas. Los tres estudiantes de la demo son filas reales de D1 del segmento M5, con identificadores sintéticos.

Transferencia internacional: el texto del chat y, si el estudiante lo autoriza, su registro de ánimo salen hacia el proveedor del modelo. Bajo la Ley 29733 y su reglamento (DS 016-2024-JUS) eso exige evaluar el marco de protección del país de destino. Se asumen: encargado de tratamiento, **sin uso para entrenar**, mínimo de texto, sin identificadores. Declararlo es condición previa a cualquier despliegue real.

3 · ALCANCE Y LÍMITES

Hace: traduce lenguaje cotidiano a un motivo no clínico; consulta servicios y calendario; propone citas compatibles con el horario real; reserva, reprograma y deriva a una persona.

NO hace, por diseño: no diagnostica ni evalúa gravedad clínica · no receta ni recomienda medicamentos o tratamientos · no es terapia · no atiende emergencias · no resuelve tareas académicas · no entrega datos de otros estudiantes · **no usa el nivel de ansiedad de nadie en tiempo de ejecución** (la segmentación es diagnóstico, no un disparador).

Apoya, no reemplaza, la atención profesional.

4 · RIESGOS Y MITIGACIONES

Riesgo	Mitigación implementada
Etiquetaje clínico	Guardrail de salida con 9 patrones; se acepta solo con negación ("no tienes…"). Si falla, cae a plantilla
Falsificación de datos	El LLM no accede a datos; todo pasa por herramientas, validadas contra el catálogo real
Autolesión no detectada por patrón	**2.ª capa:** el planificador marca `senal_de_riesgo` y activa protocolo de crisis con líneas reales (Perú 113 · Chile *4141 · SAMU)
Manipulación / prompt injection	Patrones dedicados que bloquean y reafirman el rol no clínico
Fuga de datos ajenos	Patrón dedicado; la cola de contacto lleva solo código y motivo no clínico
Sesgo del Data Pack	Tres sesgos detectados y asumidos como decisiones de diseño (§6)
Modelo fuera de rango	Indicador de confianza visible cuando predice fuera de la zona con evidencia histórica

5 · SUPERVISIÓN HUMANA

- Botón permanente **"Quiero que una persona me contacte"**, que Ruta ofrece sola ante crisis.
- **Cola de contacto humano** en la vista de Bienestar: prioridad, código y motivo **no clínico**; nunca el texto ni el estado de ánimo. **Prioridad automática** ante señal de crisis, con la línea de ayuda mientras se espera la atención.
- **Escalamiento:** si no hay turnos compatibles, se registra seguimiento y se ofrece pares como primer contacto, en vez de responder "no hay nada".
- **Auditoría por diseño:** el panel "Cómo decidió Ruta" registra cada turno —acción, motivo, herramientas, procedencia de cada dato y guardrails activados—.

6 · SESGOS DEL DATA PACK QUE ENCONTRAMOS

1. El sentimiento de D4 refleja el **canal**, no la persona (buzón 100 % `strained`, foro no) → no lo usamos como señal.
2. El motivo declarado en D4 **casi no se refleja** en su texto → no entrenamos con D4.
3. La derivación de D5 **no depende del motivo** (34,2 % de coherencia vs 33,3 % de azar) → el mapa motivo → servicio sale de D2.## 7 · Privacidad

Consentimiento expreso, informado y con finalidad; opcional y no condiciona ningún servicio.

Minimización: el horario se usa solo para calcular franjas libres; nunca notas, puntajes ni asistencia. **Identidad separada** del contenido. **ARCO completo desde la interfaz** (consultar, exportar JSON, borrar; borrar elimina también el uso posterior en el chat). **Agregación con umbral: la vista de Bienestar suprime toda celda de menos de** 10 personas**; los ánimos individuales nunca se agregan ni se comparten. **Sin uso secundario** (becas, evaluación, disciplina, publicidad) ni terceros, y **sin acceso individual** a docentes, autoridades ni áreas académicas o disciplinarias.

Cita privada: el estudiante elige el título con que su reserva aparece en el calendario; por defecto es neutro («Cita campus»), porque nombrar el servicio es lo único que delata el motivo. Sede, fecha y hora siguen visibles. **Iniciativa con permiso:** Ruta puede escribir primero solo con consentimiento de Pulse y cada disparador actúa una vez por sesión; el aviso de calendario que lo dispara es común a toda la comunidad y no se segmenta por perfil.

8 · TRANSPARENCIA HACIA EL USUARIO

Ruta se presenta como **IA de orientación no clínica** en el primer turno, en la interfaz y en cada respuesta de crisis. El estudiante **elige y rechaza** cada ruta y puede replanificar cuantas veces quiera. El panel de trazabilidad explica en lenguaje llano por qué se propuso cada cita, y Pulse dice siempre quién ve el registro. El modelo de asistencia **declara sus límites en pantalla**, incluido que no discrimina bien en el rango de esperas que ofrece la demo.

9 · MARCO NORMATIVO

Ley 29733 y su reglamento (**DS 016-2024-JUS**, vigente desde marzo de 2025), que califica los datos de salud como sensibles y exige consentimiento expreso con finalidad específica; y **Ley 31814** (**DS 115-2025-PCM**). La clasificación específica de Aethera se confirmará con asesoría legal antes de cualquier despliegue real, junto con una evaluación de impacto con un Oficial de Datos Personales. **Precedente:** Woebot cerró su app de consumo en junio de 2025 por el costo de cumplir la autorización de la FDA; Aethera evita ese camino con orientación no clínica y límites declarados.